

Technická univerzita v Košiciach

Fakulta elektrotechniky a informatiky
Katedra kybernetiky a umelej inteligencie

Extrahovanie kľúčových slov z dokumentov

Semestrálne zadanie
Manažment znalostí
Zimný semester 2025/2026

Bc. Boris Daňko
Bc. Roland Palgut
Bc. Marek Puškáš

Košice, 4. decembra 2025

Obsah

1	Popis problému	2
2	Popis existujúcich metód	2
2.1	Tradičné modely pre vyhľadávanie informácií	2
2.2	Štatistické metódy - LLT a TF-IDF	3
2.3	Latentné sémantické a vektorové modely	3
2.4	Transformerové a hybridné metódy	3
2.5	Zhrnutie	4
3	Návrh metódy a výber testovacích dát	4
4	Implementácia a dokumentácia kódu	5
4.1	Modul <code>loaders</code> – načítavanie dokumentov	5
4.2	Modul <code>preprocessing</code> - predspracovanie textu	5
4.3	Modul <code>extraction</code> - implementácia TF-IDF, YAKE a KeyBERT	5
4.4	Modul <code>visualization</code> - vizualizácia výsledkov	6
4.5	Modul <code>utils</code> export výsledkov	7
4.6	Hlavná aplikácia v <code>Streamlit</code>	7
5	Experimentovanie a vyhodnotenie	8
5.1	Zhrnutie experimentov	10
6	Referencie	11

1 Popis problému

V súčasnosti dochádza k neustálemu rastu objemu digitálnych dát vo forme textových dokumentov, vedeckých článkov, správ, e-mailov či príspevkov na sociálnych sieťach. Táto expanzia textových dát vyvoláva potrebu efektívnych metód na ich automatizované spracovanie, analýzu a porozumenie obsahu. Jednou z kľúčových úloh v oblasti spracovania prirodzeného jazyka (Natural Language Processing - NLP) a dolovania textu (Text Mining) je extrakcia kľúčových slov (Keyword Extraction - KE).

Cieľom extrakcie kľúčových slov je identifikovať tie termíny, ktoré najlepšie vystihujú obsah a tému daného dokumentu. Kľúčové slová majú zásadný význam pri úlohách, ako sú sumarizácia textu, klasifikácia dokumentov, vyhľadávanie informácií či automatické značkovanie obsahu [7]. Automatizovaná extrakcia kľúčových slov zároveň znižuje časovú náročnosť manuálneho anotovania a umožňuje spracovávať rozsiahle textové súbory bez zásahu človeka.

Podľa štúdie [7] sú hlavné výzvy v tejto oblasti spojené s presnosťou a spoľahlivosťou extrakcie. Tradičné štatistické prístupy (napr. Log-Likelihood Test - LLT) často vykazujú závislosť od referenčných korpusov, čím sa znižuje ich robustnosť. Problémom býva aj nedostatočné filtrovanie neplnovýznamových slov, ako sú predložky či spojky, ktoré dosahujú vysokú frekvenciu, no nenesú významovú hodnotu.

Ďalšou významnou výzvou je rozpoznávanie viacсловných termov (multi-word expressions) a doménovo špecifických kľúčových pojmov, ktoré sa nemusia vyskytovať v štandardných lexikálnych databázach. Moderné prístupy preto čoraz viac využívajú sémantické modely, ktoré umožňujú zachytiť významové súvislosti medzi slovami, nielen ich frekvenciu výskytu.

Problém extrakcie kľúčových slov je úzko spätý aj s inými úlohami spracovania textu, ako je sumarizácia dokumentov či automatizované odpovedanie na otázky (Question Answering - QA). Moderné extraktory kľúčových slov a sumarizačné systémy využívajú modely typu BERT alebo KeyBERT [4], ktoré umožňujú systémom lepšie pochopiť kontext používateľského dopytu a prispôbiť mu výslednú sumarizáciu či extrakciu informácií.

Celkovo možno povedať, že problém extrakcie kľúčových slov spočíva v potrebe vytvoriť metódu, ktorá bude presná, doménovo prispôsobiteľná a nezávislá od manuálneho zásahu človeka. Takáto metóda by mala zohľadniť nielen frekvenčné charakteristiky slov, ale aj ich sémantické a štylistické väzby v rámci textu.

2 Popis existujúcich metód

Extrakcia kľúčových slov sa historicky vyvíjala od jednoduchých štatistických prístupov až po moderné modely založené na hlbokých neurónových sieťach. V tejto časti sú predstavené najpoužívanejšie prístupy, ktoré sa vyskytujú v literatúre a prezentáciách k text miningu.

2.1 Tradičné modely pre vyhľadávanie informácií

V oblasti vyhľadávania informácií (Information Retrieval - IR) existujú tri základné klasické modely [6]:

1. **Boolovský model** - predstavuje najjednoduchší prístup, v ktorom sú dokumenty a dopyty reprezentované ako množiny termov. Vyhľadávanie je založené na logických operátoroch AND, OR, NOT. Tento model je efektívny, ale neumožňuje určiť mieru relevancie dokumentu.
2. **Vektorový model** - dokumenty aj dopyty sú reprezentované ako vektory termov v n-dimenzionálnom priestore. Miera podobnosti sa počíta pomocou kosínusovej podobnosti, pričom váhovanie termov je najčastejšie realizované pomocou metódy TF-IDF.
3. **Pravdepodobnostný model** - odhaduje pravdepodobnosť, že používateľ považuje dokument za relevantný pre svoj dopyt. Tento prístup predstavuje základ pre moderné re-ranking algoritmy v systémoch vyhľadávania informácií.

2.2 Štatistické metódy - LLT a TF-IDF

Tradičné korpusovo orientované metódy, ako napríklad **Dunningov Log-Likelihood Test (LLT)**, patria medzi najstaršie prístupy k extrakcii kľúčových slov. [3]. LLT hodnotí štatistickú významnosť rozdielov vo frekvencii slov medzi cieľovým a referenčným korpusom. Slová s výrazne vyššou frekvenciou v cieľovom korpuse sú považované za kľúčové. Nevýhodou LLT je jeho závislosť od kvality referenčného korpusu a neschopnosť pracovať s významovou redundanciou.

Naopak, metóda **Term Frequency-Inverse Document Frequency (TF-IDF)** [8] je jednou z najpoužívanějších techník v NLP. Hodnotí dôležitosť termu na základe jeho relatívnej frekvencie v rámci dokumentu a zriedkavosti v celom korpuse. TF-IDF umožňuje jednoduché, ale účinné určenie relevantných termov bez potreby referenčného korpusu. Využíva sa nielen v extrakcii kľúčových slov, ale aj vo vyhľadávačoch, odporúčacích systémoch či textovej klasifikácii.

2.3 Latentné sémantické a vektorové modely

Moderné NLP techniky rozširujú pôvodné frekvenčné metódy o sémantické chápanie textu. **Latentné sémantické indexovanie (LSI)** využíva singulárnu dekompozíciu matíc (SVD) na zistenie skrytých významových vzťahov medzi slovami a dokumentmi [1]. Umožňuje redukciu dimenzie a zmierňuje problémy s viacnásobným významom slov a podobnosťou výrazov v prirodzenom jazyku.

Ďalším krokom boli modely založené na distribučných reprezentáciách, ako **Word2Vec**, **GloVe** a neskôr **BERT**, ktoré umožňujú zachytiť význam slov na základe ich kontextu. Takéto modely sú základom moderných extrakčných nástrojov, ako napríklad **KeyBERT**, ktorý využíva vektorové reprezentácie a kosínusovú podobnosť na určenie najrelevantnejších kľúčových slov v texte [4].

2.4 Transformerové a hybridné metódy

Najnovšie prístupy v oblasti extrakcie kľúčových slov využívajú **transformerové architektúry** (napr. BERT, T5, PEGASUS), ktoré umožňujú pochopiť kontext textu na

hlbšej úrovni [2, 5, 9]. Tieto modely dokážu kombinovať informácie o sémantike, gramatike aj vlastnostiach programovacích jazykov a sú vhodné pre úlohy, kde je dôležité pochopiť zámer a význam celého dokumentu.

V oblasti sumarizácie a odpovedania na otázky (Question Answering) sa objavujú metódy, ktoré využívajú extrahované kľúčové slová na navádzanie modelu počas generovania sumarizovaného textu [4]. Takéto prístupy spájajú extrakciu a generáciu a predstavujú prechod k hybridným systémom schopným integrovať viaceré NLP techniky.

2.5 Zhrnutie

Klasické metódy (LLT, TF-IDF) sú výpočtovo jednoduché a interpretovateľné, no často ignorujú významové súvislosti. Na druhej strane, moderné vektorové a transformerové prístupy umožňujú modelom pochopiť kontext a význam slov, ale vyžadujú veľké množstvo dát a výpočtových zdrojov. V praxi sa preto často používajú **hybridné riešenia**, ktoré kombinujú štatistické váhovanie s vektorovou reprezentáciou textu, čím sa dosahuje kompromis medzi efektívnosťou a presnosťou extrakcie.

3 Návrh metódy a výber testovacích dát

Cieľom navrhovanej metódy je umožniť flexibilnú a modulárnu extrakciu kľúčových slov z textových dokumentov rôznych typov, ako sú PDF alebo TXT súbory. Metóda kombinuje tri prístupy: TF-IDF, YAKE a KeyBERT, pričom každý z nich poskytuje odlišný spôsob hodnotenia významu termov v dokumente.

- **TF-IDF** vyhodnocuje relatívnu dôležitosť termov na základe ich frekvencie v dokumente a zriedkavosti naprieč korpusom.
- **YAKE** je nezávislý, korpusovo orientovaný algoritmus založený na štatistike n-gramov a váh slov.
- **KeyBERT** využíva moderné transformerové modely (BERT), ktoré zachytávajú kontext a význam slov vo vete, vrátane možnosti použitia Maximal Marginal Relevance (MMR) pre diverzifikované kľúčové slová.

Všetky metódy umožňujú upravovať parametre, ako sú počet extrahovaných kľúčových slov, rozsah n-gramov alebo diverzita v KeyBERT, čo umožňuje testovanie na rôznych typoch textov a dopytoch.

Pre testovanie metódy boli použité dva zdroje dát:

1. **Vlastné nahrané dokumenty** - používateľ môže nahrať ľubovoľný súbor vo formáte TXT alebo PDF a overiť spracovanie reálnych textových dát.
2. **Vzorky zo zložky DATA/** - pripravené textové súbory s rôznou dĺžkou a obsahom, slúžiace na porovnanie výkonu a presnosti jednotlivých metód.

Pred spracovaním textu sa vykonáva predspracovanie, ktoré odstraňuje nadbytočné medzery, čísla a špeciálne znaky, čím sa zvyšuje kvalita extrahovaných kľúčových slov.

4 Implementácia a dokumentácia kódu

V rámci riešenia bola implementovaná modulárna aplikácia v jazyku Python, ktorá umožňuje extrakciu kľúčových slov pomocou troch metód: TF-IDF, YAKE a KeyBERT. Aplikácia bola realizovaná ako interaktívne grafické rozhranie v prostredí `Streamlit`, čo umožňuje používateľovi jednoducho nahrávať dokumenty, nastavovať parametre jednotlivých metód a vizualizovať výsledky.

Celá implementácia je rozdelená do viacerých logických modulov, ktoré spolupracujú na spracovaní textu, extrakcii kľúčových slov a vizualizácii výstupov. Takáto štruktúra zvyšuje prehľadnosť, uľahčuje údržbu a umožňuje jednoduché rozšírenie aplikácie o ďalšie metódy extrakcie.

4.1 Modul `loaders` – načítavanie dokumentov

Modul `loaders` obsahuje funkcie zodpovedné za načítanie a extrakciu textu zo vstupných súborov typu PDF alebo TXT. PDF sú spracovávané pomocou knižnice `PyMuPDF`, ktorá umožňuje spoľahlivú extrakciu textu z jednotlivých strán dokumentu. Textové súbory (TXT) sú načítané v kódovaní UTF-8 a následne prechádzajú základným čistením, ktoré odstraňuje LaTeX značky či špeciálne znaky.

Hlavné funkcie modulu:

- `read_pdf()`: extrahuje text z PDF dokumentov,
- `read_txt()`: načítava text z TXT súborov a vykonáva jeho základnú normalizáciu.

4.2 Modul `preprocessing` - predspracovanie textu

V rámci predspracovania je text upravený tak, aby extrakčné metódy pracovali len s relevantnými informáciami. Modul vykonáva tieto operácie:

- odstránenie duplící medzier,
- odstránenie numerických znakov,
- základná normalizácia textu.

Predspracovanie zlepšuje kvalitu extrahovaných kľúčových slov, znižuje šum a eliminuje irelevantné symboly.

4.3 Modul `extraction` - implementácia TF-IDF, YAKE a KeyBERT

Najdôležitejšia časť aplikácie je implementovaná v module `extraction`, ktorý obsahuje:

- dátové triedy (`@dataclass`) pre konfiguráciu jednotlivých metód,
- implementáciu troch extrakčných algoritmov.

TF-IDF

Metóda TF-IDF je implementovaná pomocou knižnice `scikit-learn`. Používateľ môže nastavovať:

- počet extrahovaných kľúčových slov,
- počet maximálnych črt (`max_features`),
- rozsah n-gramov.

Výsledkom je tabuľka najvýznamnejších termov zoradených podľa ich váhy TF-IDF.

YAKE

YAKE je štatistická metóda, ktorá nevyžaduje žiaden referenčný korpus. V aplikácii je použité nastavenie:

- veľkosť n-gramu,
- deduplikačný prah,
- veľkosť kontextového okna.

Výstupom je zoznam n-gramov s ich hodnotou významovosti.

KeyBERT

KeyBERT využíva jazykový model `all-MiniLM-L6-v2`, ktorý generuje vektorovú reprezentáciu dokumentu aj jednotlivých kandidátnych kľúčových fráz. K nim následne počíta kosínusovú podobnosť.

Používateľ môže aktivovať mechanizmus **Maximal Marginal Relevance (MMR)**, ktorý balansuje medzi relevanciou a diverzitou. Parametrom `diversity` je možné riadiť mieru penalizácie podobných kľúčových slov.

4.4 Modul `visualization` - vizualizácia výsledkov

Pre zlepšenie prehľadnosti výsledkov boli implementované dve hlavné vizualizačné metódy:

- horizontálny barový graf s hodnotami skóre,
- `wordcloud`, ktorý graficky znázorňuje najčastejšie alebo najrelevantnejšie termy.

Obe vizualizácie sú integrovateľné do prostredia Streamlit a sú doplnené tabuľkovým výstupom.

4.5 Modul `utils export` výsledkov

Používateľ si môže výsledky extrakcie stiahnuť vo formáte CSV. Modul obsahuje funkciu:

- `export_csv()`, ktorá zlučuje výsledky všetkých dokumentov a generuje súbor s kompletným prehľadom extrahovaných kľúčových slov.

4.6 Hlavná aplikácia v Streamlit

Hlavný spúšťač modul integruje všetky komponenty do jedného používateľsky prívetivého rozhrania. Aplikácia umožňuje:

- výber zdroja dát (upload alebo vzorové súbory),
- konfiguráciu parametrov jednotlivých metód,
- zobrazenie tabuliek, grafov a wordcloudov,
- export výsledkov.

Integrovaný mechanizmus `session_state` slúži ako cache, ktorá eliminuje opakované výpočty pri nezmenených parametroch.

Aplikácia je vďaka svojmu návrhu rozšíriteľná a vhodná na experimentálne porovnávanie rôznych metód extrakcie kľúčových slov.


Metóda	Hyperparameter	Popis a vplyv
TF-IDF	<code>max_features</code>	Maximálny počet slov zahrnutých do vektora. Obmedzuje rozmernosť vektora a vplýva na to, koľko informácií sa zachytí.
TF-IDF	<code>ngram_range</code>	Rozsah n-gramov (napr. (1,2) = unigrams + bigrams). Určuje, či sa berú do úvahy jednotlivé slová alebo aj kombinácie slov.
TF-IDF	<code>stop_words</code>	Stop slová, ktoré sa majú ignorovať. Odstraňuje bežné slová, ktoré neprispievajú k významu textu.
YAKE	<code>window_size</code>	Kontextové okno pre hodnotenie slov. Väčšie okno zachytáva širšie súvislosti.
YAKE	<code>top_k</code>	Počet najlepších kľúčových slov, ktoré sa vyberú. Ovláda množstvo extrahovaných kľúčových slov.
KeyBERT	<code>use_maxsum</code>	Minimalizuje duplicity medzi vybranými kľúčovými slovami, zvyšuje rozmanitosť extrahovaných kľúčových slov.
KeyBERT	<code>nr_candidates</code>	Počet kandidátov na výber. Viac kandidátov môže zvýšiť kvalitu extrahovaných kľúčových slov, ale spomalí spracovanie.

Tabuľka 1: Prehľad hlavných hyperparametrov použitých pri extrakcii kľúčových slov.


5 Experimentovanie a vyhodnotenie

	Keyword	Score	Document
0	covid	0.4587	A composite ranking of risk factors for COVID-19 time-t
1	variable	0.2477	A composite ranking of risk factors for COVID-19 time-t
2	factors	0.211	A composite ranking of risk factors for COVID-19 time-t
3	time	0.1896	A composite ranking of risk factors for COVID-19 time-t
4	data	0.1651	A composite ranking of risk factors for COVID-19 time-t
5	severity	0.1621	A composite ranking of risk factors for COVID-19 time-t
6	patients	0.1529	A composite ranking of risk factors for COVID-19 time-t
7	rank	0.1223	A composite ranking of risk factors for COVID-19 time-t
8	value	0.1223	A composite ranking of risk factors for COVID-19 time-t
9	analysis	0.1162	A composite ranking of risk factors for COVID-19 time-t

(a) Tabuľka kľúčových slov TF-IDF




(b) Barh graf TF-IDF



Obr. 1: Výsledok extrakcie kľúčových slov metódou TF-IDF

	Keyword	Score	Document
0	patients	0.0053	A composite ranking of risk factors for COVID-19 tir
1	severity	0.0048	A composite ranking of risk factors for COVID-19 tir
2	Wang	0.0046	A composite ranking of risk factors for COVID-19 tir
3	data	0.0042	A composite ranking of risk factors for COVID-19 tir
4	RSF	0.0036	A composite ranking of risk factors for COVID-19 tir
5	variable	0.0032	A composite ranking of risk factors for COVID-19 tir
6	risk factors	0.0027	A composite ranking of risk factors for COVID-19 tir
7	factors	0.0026	A composite ranking of risk factors for COVID-19 tir
8	severe COVID	0.0025	A composite ranking of risk factors for COVID-19 tir
9	COVID	0.0004	A composite ranking of risk factors for COVID-19 tir

(a) Tabuľka kľúčových slov YAKE




(b) Barh graf YAKE




Obr. 2: Výsledok extrakcie kľúčových slov metódou YAKE

	Keyword	Score	Document
0	analyses covid	0.5492	A composite ranking of risk factors for COVID
1	covid survival	0.5453	A composite ranking of risk factors for COVID
2	covid cohort	0.5443	A composite ranking of risk factors for COVID
3	biomarker covid	0.5407	A composite ranking of risk factors for COVID
4	factors covid	0.5401	A composite ranking of risk factors for COVID
5	covid risk	0.5353	A composite ranking of risk factors for COVID
6	factor covid	0.5348	A composite ranking of risk factors for COVID
7	covid prospective	0.5268	A composite ranking of risk factors for COVID
8	covid prognosis	0.5256	A composite ranking of risk factors for COVID
9	associated covid	0.5243	A composite ranking of risk factors for COVID

(a) Tabuľka kľúčových slov KeyBERT



(b) Barh graf KeyBERT



Obr. 3: Výsledok extrakcie kľúčových slov metódou KeyBERT

5.1 Zhrnutie experimentov

- TF-IDF je rýchly a účinný pre kratšie dokumenty s jasne definovanými termami.
- YAKE eliminuje bežné stopwords a irelevantné výrazy.
- KeyBERT poskytuje najlepší kontextový opis, hlavne pri viacslovných termoch; MMR zvyšuje diverzitu výsledkov.

Kombinácia týchto metód poskytuje robustný nástroj na extrakciu kľúčových slov a umožňuje prispôbiť parametre podľa typu a dĺžky dokumentu.

6 Referencie

- [1] Scott Deerwester et al. „Indexing by latent semantic analysis“. In: *Journal of the American society for information science* 41.6 (1990), s. 391–407.
- [2] Jacob Devlin et al. „BERT: Pre-training of deep bidirectional transformers for language understanding“. In: *NAACL-HLT* (2019), s. 4171–4186.
- [3] Ted Dunning. „Accurate methods for the statistics of surprise and coincidence“. In: *Computational Linguistics* 19.1 (1993), s. 61–74.
- [4] Maarten Grootendorst. „KeyBERT: Minimal keyword extraction with BERT“. In: *arXiv preprint arXiv:2009.10849* (2020).
- [5] Mike Lewis et al. „BART: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension“. In: *arXiv preprint arXiv:1910.13461* (2020).
- [6] Christopher D. Manning, Prabhakar Raghavan a Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge, UK: Cambridge University Press, 2008.
- [7] Stuart Rose et al. „Automatic keyword extraction from individual documents“. In: *Text Mining: Applications and Theory* (2010), s. 1–20.
- [8] Gerard Salton a Christopher Buckley. „Term-weighting approaches in automatic text retrieval“. In: *Information Processing & Management* 24.5 (1988), s. 513–523.
- [9] Jingqing Zhang, Yao Zhao a Mohammad Saleh. „PEGASUS: Pre-training with extracted gap-sentences for abstractive summarization“. In: *arXiv preprint arXiv:1912.08777* (2020).